海光BW1000、昆仑芯P800、英伟达H100 - 单节点MiniMax-M2.5模型整体测试比对报告

测试日期： 2026-03-24 ~ 2026-03-26

1. 测试背景

公司需要在多个候选开源大模型中选型，部署基于vLLM的推理服务。并需要在满足各项模型服务指标的情况下，选定芯片集采厂商。

2. 测试目标

评估英伟达，海光，昆仑芯在单机环境下运行大模型推理的能力，为后续集群采购和生产部署提供决策依据。

1. **硬件摸底**：确认各芯片型号实际规格（算力、显存、带宽）与标称值的一致性
2. **功能验证**：各模型在各芯片环境上的推理正确性和算子兼容性
3. **性能基准**：吞吐量、延迟、显存效率等关键指标
4. **单机极限**：8 卡 Tensor Parallel 的性能上限和资源利用率
5. **稳定性验证**：长时间运行下的可靠性
6. **K8S 容器化验证**：单节点 K8S 环境下GPU/DCU/XPU 调度、资源管理和服务编排能力

3. 测试环境

3.1 硬件规格

组件 \ 规格	海光	昆仑芯	英伟达	状态
节点数量	1 台	1 台	1 台	确认
芯片型号	BW1000	P800 OAM	H100	确认
芯片数量	8 张	8 张	8 张	确认
单卡算力 FP16/BF16	待确认	待确认	1979 TFLOPS （官方理论值）	⚠️ 待确认
单卡算力 FP32	待确认	待确认	67 TFLOPS （官方理论值）	⚠️ 待确认
单卡算力 FP64	待确认	待确认	34 TFLOPS （官方理论值）	⚠️ 待确认
单卡显存	65520 MiB (约64 GB)	98304 MiB（约96 GB）	80GB	确认
显存类型	待确认	待确认	HBM3	⚠️ 待确认
显存带宽	待确认	待确认	3.35 TB/s	⚠️ 待确认
单卡功耗	200 W	400 W（Enforced Power Limit）	700 W	确认
卡间互联	HSW	XPULink (XL) + PCIe Gen4 x16（跨 NUMA 显示 SYS）	NVLink 4.0	确认
CPU	Hygon C86 (128核)	Intel Xeon Platinum 8563C (208核)	Intel(R) Xeon(R) Platinum 8468 (192核)	确认
系统内存	503GiB	2.0 TiB	2.0 TiB	确认
本地存储	437G系统盘 + 1.7TiB (G73M1T9R-C-GD308)	446.6G + NVMe 4 x 3.5T (Intel SSDPF2KX038T1)	894GB 系统盘 + 7TB*4 缓存盘 + 7TB 容器盘 + 25TB 扩展盘	确认

3.2 软件栈

组件\版本	海光	昆仑芯	英伟达	说明
操作系统	Ubuntu 22.04.5 LTS	Ubuntu 22.04.5 LTS	Ubuntu 22.04.5 LTS	芯片所在物理机系统
显卡驱动	6.3.22-V1.2.0	Kunlun / XPU Driver 5.0.21.26	570.133.20/580.126.09	驱动信息
Toolkit	DTK-26.04-beta-0130-ubuntu20.04	XPU Container Runtime Hook version 1.0.5	1.17.9	DCU/XPU/GPU Toolkit
Docker	28.0.4	28.4.0	/	容器运行时
containerd	2.1.1	1.7.28	2.2.0	K8S 容器运行时（CRI）
Kubernetes	1.33	v1.28.2	1.34	单节点 All-in-One 部署
Device Plugin	v2.4.0	xpu-device-plugin v5.0.0-alpha.2	0.14.5	K8S DCU/XPU/GPU 资源管理
多卡通信库	DTK内置RCCL	无单独查询版本	NCCL	多卡通信库

3.3 推理框架

测试模型： Minimax-M2.5
节点数： 1

组件	海光	昆仑芯	英伟达	说明
vLLM	0.11.0+das.opt1.rc2.dtk2604.20260128.g0bf89b0c	0.11.0	0.15.1	海光为定制vLLM
模型精度	BF16	INT8	FP16	昆仑芯只提供了INT8量化精度的，暂没有其他精度模型
Python	3.10.12	3.10.15	3.12.3	-

4. 测试结果综述

4.1 各场景测试的整体情况及性能比对

序号	测试场景	请求参数	请求并发数	数据集	性能/精度排序	备注
场景一	vllm bench基准测试	输入上下文 10k 输出上下文 0.25k	[1, 2, 4, 8, 10, 16, 32, 64, 80, 128]	random	H100 > P800 > BW1000	**在各并发下，整体性能英伟达约是昆仑芯的2~2.6倍，是海光的10~15倍**
场景二	单、多并发超长上下文请求	输入上下文 190k 输出上下文 1k	[1, 2, 4, 8, 10]	random	H100 > P800 > BW1000	**总吞吐量性能英伟达约是昆仑芯2.9倍，海光的3.6倍； 首token性能英伟达约是昆仑芯的3.4倍，是海光的5.8倍**
场景三	多并发极限验证	输入上下文 90k 输出上下文 2k	[32, 64]	random	H100 > P800 > BW1000	**- 在本测试参数下，英伟达最大可同时稳定处理14个请求，缓存命中率稳定且正常； - 昆仑芯在18~23之间波动，缓存命中率波动较大； - 海光在1~12个之间波动，缓存命中率异常**
场景四	多轮对话	总对话轮数：1000 活跃对话数：10 对话轮次：10 输入token: 200 输出token: 100	10	pg1184.txt (seed=0)	H100 > P800 > BW1000	**英伟达的整体吞吐量约为8，是昆仑芯性能的2.8倍，是海光的13倍**
场景五	模型精度测试	num_fewshot：5 batch_size: 1	延迟分位数	mmlu_pro	H100 > P800	**昆仑芯的总体精度评分比英伟达低2.5个百分点左右; 海光没跑出来结果**
场景六	模型推理功能					**模型基础能力验证，3种芯片的基础支持能力基本都可通过**

4.2 测试问题汇总

4.2.1 性能问题

从测试的各场景来看，海光的环境性能太慢，模型精度测试使用基础的文本数据集都未能跑出来。

4.2.2 长上下文高并发稳定性问题

在场景三中，海光环境的测试发现模型同时处理的请求数波动比较大（在1~12之间频繁波动），且使用随机种子数据的情况下缓存命中率异常（16%左右，正常应该在0~3%之间）
而昆仑芯环境处理请求数波动算是稳定，不过缓存命中率波动比较大（在2%~16%左右之间波动）

4.3 模型部署问题汇总

4.3.1 思考模式问题

对于思考模式的启动参数，海光和昆仑芯环境部署按照--reasoning-parser minimax_m2启动后，响应内容依然是直接写入到content里，而不是写入到think标签里。

可能原因：
猜测可能跟vLLM的版本较低有关。

解决方案：

- 昆仑芯：建议参数变更为 --reasoning-parser_appened_think minimax_m2
  验证结果：变更后，think标签出现了，不过按照_appened_think的这个设计，think标签的内容会被合并到content里, 由此带来另一个问题是tool_call工具调用功能失败。
- 海光：后续修复，修复后重新传镜像
  验证结果：还未提供最新镜像

4.3.2 专家并行模式问题

对于昆仑芯的vLLM模型部署，在TP=8的情况下，若同时启动专家并行模式，这种情况下是双重高强度通信叠加，在 BKCL / XCCL 上，非常容易出现以下问题：

- buffer size 计算错误
- rank 不一致
- 通信 hang / 越界 （实际测试确实遇到了该问题）

解决方案
昆仑芯的模型部署暂不启用专家并行

4.4 GPU、DCU、XPU监控问题说明

由于测试发现海光芯片的监控指令兼容hy-smi和rocm-smi，开始的监控脚本使用的是rocm-smi，很遗憾的是测试开始后并没有真正抓取到DCU的使用情况； 昆仑芯的监控指令xpu-smi指令未打进所提供的镜像里，本次测试暂没有对昆仑芯进行XPU使用监控。 英伟达的GPU使用情况监控记录完整的获取到了，不过由于仅获取这一款芯片的监控情况，本测试报告里暂不体现不同芯片间的GPU/DCU/XPU的监控信息比对。

以下是每个测试场景的详细结果报告

测试场景一：vllm bench基准测试

测试目标：在相同请求数、输入上下文长度、输出上下文长度参数下，使用vllm bench serve工具对并发数逐级增加场景的性能基准验证，并对不同芯片的性能指标进行比对。

主要采集指标：

指标	单位	含义
TTFT	ms	Time To First Token，首 token 延迟
TPOT	ms/token	Time Per Output Token，每 token 生成时间
Throughput	tokens/s	系统总吞吐
QPS	requests/s	请求吞吐
P50/P95/P99 Latency	ms	延迟分位数

📊 测试概览

项目	配置	备注
数据集	random	
并发数	1, 2, 4, 8, 10, 16, 32, 64, 80, 128	
总请求数	320	
请求输入上下文长度	10240（10k）	
请求输出上下文长度	256（0.25k）	
模型	MiniMax-M2.5	
被测芯片	Hygon_BW1000, Kunlun_P800, NVIDIA_H100	

🤖 vLLM启动配置信息

参数名称	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
max-model-len	196608	196608	196608
max-num-seqs	10	10	10
max-num-batched-tokens	8192	8192	8192
gpu-memory-utilization	0.95	0.95	0.85
dp	1	1	1
tp	8	8	8
pp	1	1	1
enable-export-parallel	True	False	True
tool-call-parser	minimax_m2	minimax_m2	minimax_m2
reasoning-parser	minimax_m2 (不生效)	minimax_m2 (不生效)	minimax_m2

📈 不同芯片各并发级别性能对比

1 并发

服务基准结果

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
成功请求数	320	320	320
失败请求数	0	0	0
测试持续时间 (s)	13148.00	1892.60	857.88
总输入 tokens	3276748	3276748	3276800
总生成 tokens	80226	79410	81920
请求吞吐量 (req/s)	0.02	0.17	**0.37** ⭐
输出 token 吞吐量 (tok/s)	6.10	41.96	**95.49** ⭐
峰值输出 token 吞吐量 (tok/s)	8.00	50.00	**110.00** ⭐
峰值并发请求数	2.00	2.00	2.00
总 token 吞吐量 (tok/s)	255.32	1773.30	**3915.14** ⭐

首Token延迟 (TTFT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TTFT (ms)	1958.35	817.94	**321.42** ⭐
中位 TTFT (ms)	1964.30	824.23	**306.62** ⭐
P95 TTFT (ms)	1977.98	835.94	**313.59** ⭐
P99 TTFT (ms)	1990.88	**842.86** ⭐	1181.54

每Token生成时间 (TPOT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TPOT (ms)	156.69	20.62	**9.25** ⭐
中位 TPOT (ms)	156.16	20.62	**9.23** ⭐
P95 TPOT (ms)	163.40	20.65	**9.23** ⭐
P99 TPOT (ms)	168.81	20.67	**9.89** ⭐

Token间延迟 (ITL)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 ITL (ms)	156.23	20.56	**9.23** ⭐
中位 ITL (ms)	155.76	20.60	**9.22** ⭐
P95 ITL (ms)	162.28	20.77	**9.41** ⭐
P99 ITL (ms)	191.32	21.22	**9.90** ⭐

2 并发

服务基准结果

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
成功请求数	320	320	320
失败请求数	0	0	0
测试持续时间 (s)	6965.73	1106.64	485.01
总输入 tokens	3276748	3276748	3276800
总生成 tokens	80297	79281	81920
请求吞吐量 (req/s)	0.05	0.29	**0.66** ⭐
输出 token 吞吐量 (tok/s)	11.53	71.64	**168.90** ⭐
峰值输出 token 吞吐量 (tok/s)	15.00	93.00	**207.00** ⭐
峰值并发请求数	4.00	4.00	4.00
总 token 吞吐量 (tok/s)	481.94	3032.63	**6925.05** ⭐

首Token延迟 (TTFT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TTFT (ms)	2052.00	874.08	**427.60** ⭐
中位 TTFT (ms)	2024.87	833.51	**418.60** ⭐
P95 TTFT (ms)	2038.41	1182.06	**545.11** ⭐
P99 TTFT (ms)	3752.70	1442.65	**549.04** ⭐

每Token生成时间 (TPOT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TPOT (ms)	165.84	24.43	**10.21** ⭐
中位 TPOT (ms)	166.01	24.54	**10.22** ⭐
P95 TPOT (ms)	168.30	25.69	**10.69** ⭐
P99 TPOT (ms)	173.26	27.19	**10.70** ⭐

Token间延迟 (ITL)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 ITL (ms)	165.31	24.46	**10.18** ⭐
中位 ITL (ms)	158.87	21.87	**9.75** ⭐
P95 ITL (ms)	164.70	22.10	**9.91** ⭐
P99 ITL (ms)	168.68	55.05	**10.48** ⭐

---

4 并发

服务基准结果

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
成功请求数	320	320	320
失败请求数	0	0	0
测试持续时间 (s)	3741.16	696.02	284.59
总输入 tokens	3276748	3276748	3276800
总生成 tokens	80266	79960	81920
请求吞吐量 (req/s)	0.09	0.46	**1.12** ⭐
输出 token 吞吐量 (tok/s)	21.45	114.88	**287.86** ⭐
峰值输出 token 吞吐量 (tok/s)	29.00	173.00	**401.00** ⭐
峰值并发请求数	7.00	7.00	8.00
总 token 吞吐量 (tok/s)	897.32	4822.70	**11802.07** ⭐

首Token延迟 (TTFT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TTFT (ms)	2185.58	930.47	**694.79** ⭐
中位 TTFT (ms)	2038.85	843.28	**666.62** ⭐
P95 TTFT (ms)	3821.77	1458.49	**992.60** ⭐
P99 TTFT (ms)	5568.67	2064.95	**995.93** ⭐

每Token生成时间 (TPOT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TPOT (ms)	177.49	31.10	**11.22** ⭐
中位 TPOT (ms)	177.87	31.38	**11.32** ⭐
P95 TPOT (ms)	183.40	34.01	**12.78** ⭐
P99 TPOT (ms)	186.11	35.52	**12.80** ⭐

Token间延迟 (ITL)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 ITL (ms)	176.98	31.29	**11.19** ⭐
中位 ITL (ms)	157.22	23.38	**10.08** ⭐
P95 ITL (ms)	162.59	24.17	**10.33** ⭐
P99 ITL (ms)	1872.44	534.67	**11.28** ⭐

---

8 并发

服务基准结果

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
成功请求数	320	320	320
失败请求数	0	0	0
测试持续时间 (s)	2176.31	508.44	196.85
总输入 tokens	3276748	3276748	3276800
总生成 tokens	80442	78888	81920
请求吞吐量 (req/s)	0.15	0.63	**1.63** ⭐
输出 token 吞吐量 (tok/s)	36.96	155.16	**416.15** ⭐
峰值输出 token 吞吐量 (tok/s)	59.00	280.00	**680.00** ⭐
峰值并发请求数	15.00	13.00	16.00
总 token 吞吐量 (tok/s)	1542.60	6599.86	**17062.16** ⭐

首Token延迟 (TTFT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TTFT (ms)	3297.61	1140.45	**961.02** ⭐
中位 TTFT (ms)	2089.60	**847.01** ⭐	1023.59
P95 TTFT (ms)	10888.09	2055.50	**1474.23** ⭐
P99 TTFT (ms)	13004.02	3816.59	**1603.43** ⭐

每Token生成时间 (TPOT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TPOT (ms)	201.95	46.86	**15.53** ⭐
中位 TPOT (ms)	205.98	47.37	**15.30** ⭐
P95 TPOT (ms)	212.79	50.43	**18.09** ⭐
P99 TPOT (ms)	221.53	56.20	**18.14** ⭐

Token间延迟 (ITL)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 ITL (ms)	201.36	47.59	**15.48** ⭐
中位 ITL (ms)	157.25	29.16	**11.93** ⭐
P95 ITL (ms)	163.19	60.47	**12.35** ⭐
P99 ITL (ms)	1931.02	541.52	**187.51** ⭐

10 并发

服务基准结果

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
成功请求数	320	320	320
失败请求数	0	0	0
测试持续时间 (s)	1854.59	479.27	183.23
总输入 tokens	3276748	3276748	3276800
总生成 tokens	80517	79598	81920
请求吞吐量 (req/s)	0.17	0.67	**1.75** ⭐
输出 token 吞吐量 (tok/s)	43.42	166.08	**447.09** ⭐
峰值输出 token 吞吐量 (tok/s)	73.00	311.00	**759.00** ⭐
峰值并发请求数	16.00	15.00	18.00
总 token 吞吐量 (tok/s)	1810.25	7003.02	**18330.76** ⭐

首Token延迟 (TTFT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TTFT (ms)	3593.83	1232.27	**1012.23** ⭐
中位 TTFT (ms)	2084.97	**859.67** ⭐	1139.42
P95 TTFT (ms)	10884.20	2782.24	**1398.62** ⭐
P99 TTFT (ms)	16227.56	4707.14	**1604.56** ⭐

每Token生成时间 (TPOT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TPOT (ms)	214.72	55.09	**18.48** ⭐
中位 TPOT (ms)	219.17	56.07	**17.95** ⭐
P95 TPOT (ms)	227.12	59.03	**21.21** ⭐
P99 TPOT (ms)	234.69	61.46	**21.28** ⭐

Token间延迟 (ITL)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 ITL (ms)	214.01	54.93	**18.42** ⭐
中位 ITL (ms)	157.32	32.95	**13.38** ⭐
P95 ITL (ms)	163.94	188.79	**14.18** ⭐
P99 ITL (ms)	1924.45	542.02	**190.68** ⭐

---

16 并发

服务基准结果

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
成功请求数	320	320	320
失败请求数	0	0	0
测试持续时间 (s)	1847.45	475.87	182.26
总输入 tokens	3276748	3276748	3276800
总生成 tokens	80132	79221	81920
请求吞吐量 (req/s)	0.17	0.67	**1.76** ⭐
输出 token 吞吐量 (tok/s)	43.37	166.48	**449.46** ⭐
峰值输出 token 吞吐量 (tok/s)	71.00	311.00	**760.00** ⭐
峰值并发请求数	20.00	18.00	22.00
总 token 吞吐量 (tok/s)	1817.04	7052.24	**18427.76** ⭐

首Token延迟 (TTFT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TTFT (ms)	36634.82	9584.38	**3864.33** ⭐
中位 TTFT (ms)	35931.86	9886.81	**5018.01** ⭐
P95 TTFT (ms)	58125.31	11728.12	**5362.36** ⭐
P99 TTFT (ms)	63884.93	15927.16	**6358.44** ⭐

每Token生成时间 (TPOT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TPOT (ms)	216.95	56.41	**20.24** ⭐
中位 TPOT (ms)	219.89	56.34	**20.22** ⭐
P95 TPOT (ms)	228.33	59.38	**21.28** ⭐
P99 TPOT (ms)	246.10	63.60	**21.35** ⭐

Token间延迟 (ITL)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 ITL (ms)	216.16	56.28	**20.19** ⭐
中位 ITL (ms)	157.71	32.98	**13.38** ⭐
P95 ITL (ms)	164.13	188.87	**15.08** ⭐
P99 ITL (ms)	1923.89	540.05	**189.48** ⭐

---

32 并发

服务基准结果

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
成功请求数	320	320	320
失败请求数	0	0	0
测试持续时间 (s)	1847.10	477.04	182.30
总输入 tokens	3276748	3276748	3276800
总生成 tokens	80324	79281	81920
请求吞吐量 (req/s)	0.17	0.67	**1.76** ⭐
输出 token 吞吐量 (tok/s)	43.49	166.19	**449.36** ⭐
峰值输出 token 吞吐量 (tok/s)	71.00	311.00	**760.00** ⭐
峰值并发请求数	36.00	34.00	38.00
总 token 吞吐量 (tok/s)	1817.48	7035.16	**18423.63** ⭐

首Token延迟 (TTFT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TTFT (ms)	122875.63	32040.77	**12498.42** ⭐
中位 TTFT (ms)	124891.14	32900.58	**12483.01** ⭐
P95 TTFT (ms)	147416.43	36489.30	**15827.75** ⭐
P99 TTFT (ms)	150615.03	37797.90	**15877.21** ⭐

每Token生成时间 (TPOT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TPOT (ms)	218.56	56.49	**20.18** ⭐
中位 TPOT (ms)	220.42	56.33	**20.21** ⭐
P95 TPOT (ms)	227.78	60.89	**20.81** ⭐
P99 TPOT (ms)	236.50	63.90	**20.85** ⭐

Token间延迟 (ITL)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 ITL (ms)	217.96	56.27	**20.12** ⭐
中位 ITL (ms)	157.77	32.96	**13.40** ⭐
P95 ITL (ms)	165.32	188.78	**14.81** ⭐
P99 ITL (ms)	1924.43	540.00	**189.42** ⭐

---

64 并发

服务基准结果

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
成功请求数	320	320	320
失败请求数	0	0	0
测试持续时间 (s)	1864.45	477.53	182.36
总输入 tokens	3276748	3276748	3276800
总生成 tokens	80461	79358	81920
请求吞吐量 (req/s)	0.17	0.67	**1.75** ⭐
输出 token 吞吐量 (tok/s)	43.16	166.18	**449.23** ⭐
峰值输出 token 吞吐量 (tok/s)	71.00	310.00	**760.00** ⭐
峰值并发请求数	68.00	67.00	70.00
总 token 吞吐量 (tok/s)	1800.65	7027.99	**18418.46** ⭐

首Token延迟 (TTFT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TTFT (ms)	284382.45	73483.64	**28345.01** ⭐
中位 TTFT (ms)	308175.63	80355.19	**29997.18** ⭐
P95 TTFT (ms)	336951.30	83007.06	**33326.91** ⭐
P99 TTFT (ms)	343209.29	86884.30	**34028.75** ⭐

每Token生成时间 (TPOT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TPOT (ms)	218.23	56.43	**20.25** ⭐
中位 TPOT (ms)	219.77	56.32	**20.21** ⭐
P95 TPOT (ms)	231.26	61.17	**21.30** ⭐
P99 TPOT (ms)	241.21	63.21	**21.36** ⭐

Token间延迟 (ITL)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 ITL (ms)	217.55	56.24	**20.19** ⭐
中位 ITL (ms)	157.89	32.93	**13.38** ⭐
P95 ITL (ms)	168.53	188.83	**15.08** ⭐
P99 ITL (ms)	1925.72	540.19	**189.46** ⭐

---

80 并发

服务基准结果

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
成功请求数	320	320	320
失败请求数	0	0	0
测试持续时间 (s)	1847.88	476.99	182.55
总输入 tokens	3276748	3276748	3276800
总生成 tokens	80365	79327	81920
请求吞吐量 (req/s)	0.17	0.67	**1.75** ⭐
输出 token 吞吐量 (tok/s)	43.49	166.31	**448.76** ⭐
峰值输出 token 吞吐量 (tok/s)	71.00	311.00	**760.00** ⭐
峰值并发请求数	84.00	82.00	86.00
总 token 吞吐量 (tok/s)	1816.74	7035.98	**18399.06** ⭐

首Token延迟 (TTFT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TTFT (ms)	354268.91	92691.66	**35639.41** ⭐
中位 TTFT (ms)	402242.69	104622.58	**40443.15** ⭐
P95 TTFT (ms)	409210.34	106423.96	**40507.57** ⭐
P99 TTFT (ms)	418658.91	110973.71	**41499.32** ⭐

每Token生成时间 (TPOT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TPOT (ms)	217.84	56.36	**20.27** ⭐
中位 TPOT (ms)	220.16	56.32	**20.23** ⭐
P95 TPOT (ms)	227.98	60.21	**21.31** ⭐
P99 TPOT (ms)	239.73	63.17	**21.36** ⭐

Token间延迟 (ITL)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 ITL (ms)	217.14	56.17	**20.21** ⭐
中位 ITL (ms)	157.45	32.94	**13.40** ⭐
P95 ITL (ms)	164.60	188.95	**15.23** ⭐
P99 ITL (ms)	1924.81	540.58	**189.49** ⭐

---

128 并发

服务基准结果

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
成功请求数	320	320	320
失败请求数	0	0	0
测试持续时间 (s)	1861.45	477.43	182.53
总输入 tokens	3276748	3276748	3276800
总生成 tokens	80952	79008	81920
请求吞吐量 (req/s)	0.17	0.67	**1.75** ⭐
输出 token 吞吐量 (tok/s)	43.49	165.49	**448.81** ⭐
峰值输出 token 吞吐量 (tok/s)	71.00	310.00	**760.00** ⭐
峰值并发请求数	132.00	131.00	134.00
总 token 吞吐量 (tok/s)	1803.81	7028.75	**18401.38** ⭐

首Token延迟 (TTFT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TTFT (ms)	551191.53	141780.60	**54641.25** ⭐
中位 TTFT (ms)	677657.74	174046.20	**66656.46** ⭐
P95 TTFT (ms)	697287.77	176900.75	**68581.20** ⭐
P99 TTFT (ms)	705024.57	180930.81	**69614.62** ⭐

每Token生成时间 (TPOT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TPOT (ms)	217.69	56.48	**20.25** ⭐
中位 TPOT (ms)	220.15	56.36	**20.22** ⭐
P95 TPOT (ms)	227.58	61.46	**21.29** ⭐
P99 TPOT (ms)	233.25	65.38	**21.35** ⭐

Token间延迟 (ITL)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 ITL (ms)	216.99	56.35	**20.20** ⭐
中位 ITL (ms)	157.95	32.95	**13.39** ⭐
P95 ITL (ms)	164.61	188.89	**15.04** ⭐
P99 ITL (ms)	1925.47	539.85	**189.51** ⭐

📈 性能趋势对比图 (所有芯片)

📝 场景一测试结果分析总结

1. 吞吐量性能对比

请求吞吐量 (QPS): 在低并发(1-4)场景下，NVIDIA_H100 表现最佳，平均 0.72 req/s； 在中并发(8-32)场景下，NVIDIA_H100 表现最佳，平均 1.72 req/s； 在高并发(64-128)场景下，NVIDIA_H100 表现最佳，平均 1.75 req/s。

Token吞吐量: NVIDIA_H100 在128并发时达到最高吞吐量 18401 tok/s。

2. 首Token延迟 (TTFT) 对比

低并发(1-4): NVIDIA_H100 TTFT最优，平均 909ms

高并发(64-128): NVIDIA_H100 TTFT最优，平均 48381ms

⚠️ **注意**: 海光芯片在高并发下TTFT延迟显著高于其他芯片，约为NVIDIA的10倍

3. Token生成时间 (TPOT) 对比

最优表现: NVIDIA_H100 在各并发下TPOT表现最佳，128并发时仅为 9.89ms

⚠️ **注意**: 海光芯片TPOT延迟明显高于NVIDIA，约为 10.9 倍

4. 综合评估

综合性能: NVIDIA_H100 在所有测试场景中综合表现最优

请求吞吐量 (Request Throughput) - 各并发最优

Concurrency	Best Chip	Performance
1	NVIDIA_H100	0.37 req/s
2	NVIDIA_H100	0.66 req/s
4	NVIDIA_H100	1.12 req/s
8	NVIDIA_H100	1.63 req/s
10	NVIDIA_H100	1.75 req/s
16	NVIDIA_H100	1.76 req/s
32	NVIDIA_H100	1.76 req/s
64	NVIDIA_H100	1.75 req/s
80	NVIDIA_H100	1.75 req/s
128	NVIDIA_H100	1.75 req/s

Token总吞吐量 (Total Token Throughput) - 各并发最优

Concurrency	Best Chip	Performance
1	NVIDIA_H100	3915 tok/s
2	NVIDIA_H100	6925 tok/s
4	NVIDIA_H100	11802 tok/s
8	NVIDIA_H100	17062 tok/s
10	NVIDIA_H100	18331 tok/s
16	NVIDIA_H100	18428 tok/s
32	NVIDIA_H100	18424 tok/s
64	NVIDIA_H100	18418 tok/s
80	NVIDIA_H100	18399 tok/s
128	NVIDIA_H100	18401 tok/s

TTFT P99 - 各并发最优

Concurrency	Best Chip	Latency
1	Kunlun_P800	842.86 ms
2	NVIDIA_H100	549.04 ms
4	NVIDIA_H100	995.93 ms
8	NVIDIA_H100	1603.43 ms
10	NVIDIA_H100	1604.56 ms
16	NVIDIA_H100	6358.44 ms
32	NVIDIA_H100	15877.21 ms
64	NVIDIA_H100	34028.75 ms
80	NVIDIA_H100	41499.32 ms
128	NVIDIA_H100	69614.62 ms

TPOT P99 - 各并发最优

Concurrency	Best Chip	Latency
1	NVIDIA_H100	9.89 ms
2	NVIDIA_H100	10.70 ms
4	NVIDIA_H100	12.80 ms
8	NVIDIA_H100	18.14 ms
10	NVIDIA_H100	21.28 ms
16	NVIDIA_H100	21.35 ms
32	NVIDIA_H100	20.85 ms
64	NVIDIA_H100	21.36 ms
80	NVIDIA_H100	21.36 ms
128	NVIDIA_H100	21.35 ms

测试场景二：单、多并发超长上下文请求测试

测试目标：获取单并发超长上下文请求（接近启动参数的max-len 192k）下各芯片的性能指标。

📊 测试概览

项目	配置	备注
数据集	random	
并发数	1	
总请求数	100	
请求输入上下文长度	194560（190k）	
请求输出上下文长度	1024（1k）	
模型	MiniMax-M2.5	
被测芯片	Hygon_BW1000, Kunlun_P800, NVIDIA_H100	

🤖 vLLM启动配置信息

参数名称	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
max-model-len	196608	196608	196608
max-num-seqs	10	10	10
max-num-batched-tokens	8192	8192	8192
gpu-memory-utilization	0.95	0.95	0.85
dp	1	1	1
tp	8	8	8
pp	1	1	1
enable-export-parallel	True	False	True
tool-call-parser	minimax_m2	minimax_m2	minimax_m2
reasoning-parser	minimax_m2 (不生效)	minimax_m2 (不生效)	minimax_m2

📈 超长上下文请求各并发级别性能对比

1 并发

服务基准结果

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
成功请求数	100	100	100
失败请求数	0	0	0
测试持续时间 (s)	8655.55	4735.72	2400.85
总输入 tokens	19456000	19456000	19456000
总生成 tokens	14970	15277	102400
请求吞吐量 (req/s)	0.01	0.02	**0.04** ⭐
输出 token 吞吐量 (tok/s)	1.73	3.23	**42.65** ⭐
峰值输出 token 吞吐量 (tok/s)	8.00	20.00	**79.00** ⭐
峰值并发请求数	2.00	2.00	2.00
总 token 吞吐量 (tok/s)	2249.54	4111.58	**8146.44** ⭐

首Token延迟 (TTFT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TTFT (ms)	63442.80	39047.26	**10837.53** ⭐
中位 TTFT (ms)	64113.52	39430.52	**10939.07** ⭐
P95 TTFT (ms)	64263.01	39464.93	**10981.68** ⭐
P99 TTFT (ms)	64339.96	39495.63	**10999.63** ⭐

每Token生成时间 (TPOT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TPOT (ms)	155.46	54.79	**12.87** ⭐
中位 TPOT (ms)	155.38	54.76	**12.87** ⭐
P95 TPOT (ms)	157.34	54.81	**12.93** ⭐
P99 TPOT (ms)	157.59	56.01	**13.03** ⭐

Token间延迟 (ITL)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 ITL (ms)	155.43	54.75	**12.93** ⭐
中位 ITL (ms)	155.08	54.74	**12.87** ⭐
P95 ITL (ms)	161.33	54.99	**13.04** ⭐
P99 ITL (ms)	171.35	57.01	**13.89** ⭐

📊 单并发下的芯片间性能比对柱状图

2 并发

服务基准结果

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
成功请求数	100	100	100
失败请求数	0	0	0
测试持续时间 (s)	8755.03	4456.34	1829.83
总输入 tokens	19456000	19456000	19456000
总生成 tokens	15263	20670	102400
请求吞吐量 (req/s)	0.01	0.02	**0.05** ⭐
输出 token 吞吐量 (tok/s)	1.74	4.64	**55.96** ⭐
峰值输出 token 吞吐量 (tok/s)	8.00	37.00	**134.00** ⭐
峰值并发请求数	3.00	3.00	4.00
总 token 吞吐量 (tok/s)	2224.01	4370.55	**10688.67** ⭐

首Token延迟 (TTFT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TTFT (ms)	150613.30	44931.50	**15942.01** ⭐
中位 TTFT (ms)	148787.19	40375.08	**11898.47** ⭐
P95 TTFT (ms)	166905.14	75502.31	**21401.99** ⭐
P99 TTFT (ms)	288709.33	78394.34	**21510.81** ⭐

每Token生成时间 (TPOT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TPOT (ms)	155.72	207.16	**20.19** ⭐
中位 TPOT (ms)	155.74	134.72	**22.20** ⭐
P95 TPOT (ms)	157.55	546.28	**25.27** ⭐
P99 TPOT (ms)	158.61	632.60	**25.37** ⭐

Token间延迟 (ITL)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 ITL (ms)	155.59	214.50	**20.27** ⭐
中位 ITL (ms)	155.14	56.01	**15.14** ⭐
P95 ITL (ms)	161.19	1622.96	**15.37** ⭐
P99 ITL (ms)	**165.40** ⭐	2481.47	324.31

4 并发

服务基准结果

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
成功请求数	100	100	100
失败请求数	0	0	0
测试持续时间 (s)	9218.65	4054.16	1512.09
总输入 tokens	19456000	19456000	19456000
总生成 tokens	16504	14852	102400
请求吞吐量 (req/s)	0.01	0.02	**0.07** ⭐
输出 token 吞吐量 (tok/s)	1.79	3.66	**67.72** ⭐
峰值输出 token 吞吐量 (tok/s)	8.00	73.00	**224.00** ⭐
峰值并发请求数	5.00	7.00	7.00
总 token 吞吐量 (tok/s)	2112.29	4802.69	**12934.69** ⭐

首Token延迟 (TTFT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TTFT (ms)	337958.92	58703.34	**19249.51** ⭐
中位 TTFT (ms)	333410.25	47826.04	**17145.98** ⭐
P95 TTFT (ms)	408152.45	117588.50	**32208.02** ⭐
P99 TTFT (ms)	465366.18	120034.28	**33469.80** ⭐

每Token生成时间 (TPOT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TPOT (ms)	155.34	690.63	**40.26** ⭐
中位 TPOT (ms)	155.21	711.54	**38.56** ⭐
P95 TPOT (ms)	157.16	1017.54	**48.44** ⭐
P99 TPOT (ms)	157.97	1199.30	**49.23** ⭐

Token间延迟 (ITL)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 ITL (ms)	155.33	696.27	**40.43** ⭐
中位 ITL (ms)	155.01	57.66	**18.08** ⭐
P95 ITL (ms)	**161.53** ⭐	2456.10	322.71
P99 ITL (ms)	**172.37** ⭐	2690.67	587.80

8 并发

服务基准结果

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
成功请求数	100	100	100
失败请求数 0	0	0	
测试持续时间 (s)	10080.21	4046.25	1447.68
总输入 tokens	19456000	19456000	19456000
总生成 tokens	18194	26139	102400
请求吞吐量 (req/s)	0.01	0.02	**0.07** ⭐
输出 token 吞吐量 (tok/s)	1.80	6.46	**70.73** ⭐
峰值输出 token 吞吐量 (tok/s)	8.00	136.00	**258.00** ⭐
峰值并发请求数	9.00	11.00	9.00
总 token 吞吐量 (tok/s)	1931.92	4814.86	**13510.17** ⭐

首Token延迟 (TTFT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TTFT (ms)	749261.20	91164.54	**35343.53** ⭐
中位 TTFT (ms)	753725.89	80497.31	**28506.97** ⭐
P95 TTFT (ms)	885387.37	161053.87	**48662.62** ⭐
P99 TTFT (ms)	895508.47	240236.55	**87006.65** ⭐

每Token生成时间 (TPOT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TPOT (ms)	155.65	1222.97	**77.70** ⭐
中位 TPOT (ms)	155.63	1352.12	**79.33** ⭐
P95 TPOT (ms)	157.26	1655.50	**81.16** ⭐
P99 TPOT (ms)	158.33	1664.08	**82.14** ⭐

Token间延迟 (ITL)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 ITL (ms)	155.48	881.62	**78.03** ⭐
中位 ITL (ms)	155.32	638.32	**23.46** ⭐
P95 ITL (ms)	**162.60** ⭐	2524.13	475.53
P99 ITL (ms)	**176.01** ⭐	2711.55	653.83

10 并发

服务基准结果

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
成功请求数	100	100	100
失败请求数	0	0	0
测试持续时间 (s)	10345.13	3958.73	1441.45
总输入 tokens	19456000	19456000	19456000
总生成 tokens	18251	16821	102400
请求吞吐量 (req/s)	0.01	0.03	**0.07** ⭐
输出 token 吞吐量 (tok/s)	1.76	4.25	**71.04** ⭐
峰值输出 token 吞吐量 (tok/s)	8.00	127.00	**258.00** ⭐
峰值并发请求数	11.00	12.00	11.00
总 token 吞吐量 (tok/s)	1882.46	4918.95	**13568.55** ⭐

首Token延迟 (TTFT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TTFT (ms)	968440.58	146180.13	**62956.13** ⭐
中位 TTFT (ms)	976574.85	148167.77	**68872.29** ⭐
P95 TTFT (ms)	1150451.17	230342.85	**71040.37** ⭐
P99 TTFT (ms)	1217634.97	319223.30	**109375.21** ⭐

每Token生成时间 (TPOT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TPOT (ms)	155.38	1563.07	**77.39** ⭐
中位 TPOT (ms)	155.41	1626.53	**79.19** ⭐
P95 TPOT (ms)	157.10	1659.06	**80.34** ⭐
P99 TPOT (ms)	157.72	1661.83	**80.42** ⭐

Token间延迟 (ITL)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 ITL (ms)	155.24	1473.37	**77.73** ⭐
中位 ITL (ms)	154.80	1497.41	**23.48** ⭐
P95 ITL (ms)	**160.39** ⭐	2628.68	472.33
P99 ITL (ms)	**164.43** ⭐	2738.47	649.04

📈 超长上下文测试性能趋势对比图 (所有芯片)

综合性能: NVIDIA_H100 在所有测试场景中综合表现最优

请求吞吐量 (Request Throughput) - 各并发最优

Concurrency	Best Chip	Performance
1	NVIDIA_H100	0.04 req/s
2	NVIDIA_H100	0.05 req/s
4	NVIDIA_H100	0.07 req/s
8	NVIDIA_H100	0.07 req/s
10	NVIDIA_H100	0.07 req/s

Token总吞吐量 (Total Token Throughput) - 各并发最优

Concurrency	Best Chip	Performance
1	NVIDIA_H100	8146 tok/s
2	NVIDIA_H100	10689 tok/s
4	NVIDIA_H100	12935 tok/s
8	NVIDIA_H100	13510 tok/s
10	NVIDIA_H100	13569 tok/s

TTFT P99 - 各并发最优

Concurrency	Best Chip	Latency
1	NVIDIA_H100	10999.63 ms
2	NVIDIA_H100	21510.81 ms
4	NVIDIA_H100	33469.80 ms
8	NVIDIA_H100	87006.65 ms
10	NVIDIA_H100	109375.21 ms

TPOT P99 - 各并发最优

Concurrency	Best Chip	Latency
1	NVIDIA_H100	13.03 ms
2	NVIDIA_H100	25.37 ms
4	NVIDIA_H100	49.23 ms
8	NVIDIA_H100	82.14 ms
10	NVIDIA_H100	80.42 ms

测试场景三：多并发极限验证

测试目标：使用线上真实的请求数据，在多并发的情况下，验证各芯片单节点同时能处理的最大请求数。

说明：由于测试发现三种芯片在32并发下已经可以获取到各芯片能同时处理的请求数极限值，且海光的环境在64并发下还未完成测试，因此，本报告仅列出32并发下的对比结果。

📊 测试概览

项目	配置	备注
数据集	random	
并发数	32, 64	
总请求数	1000	
请求输入上下文长度	90000（约90k）	
请求输出上下文长度	2000（约2k）	
模型	MiniMax-M2.5	
被测芯片	Hygon_BW1000, Kunlun_P800, NVIDIA_H100	

🤖 vLLM启动配置信息

参数名称	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
max-model-len	196608	196608	196608
max-num-seqs	64	64	64
max-num-batched-tokens	8192	8192	8192
gpu-memory-utilization	0.95	0.95	0.85
dp	1	1	1
tp	8	8	8
pp	1	1	1
enable-export-parallel	True	False	True
tool-call-parser	minimax_m2	minimax_m2	minimax_m2
reasoning-parser	minimax_m2 (不生效)	minimax_m2 (不生效)	minimax_m2

📈 各并发级别性能对比

32 并发

服务基准结果

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
成功请求数	1000	1000	1000
失败请求数	0	0	0
测试持续时间 (s)	60102.65	11642.33	6978.61
总输入 tokens	90000000	90000000	90000000
总生成 tokens	323447	245458	2000000
请求吞吐量 (req/s)	0.02	0.09	**0.14** ⭐
输出 token 吞吐量 (tok/s)	5.38	21.08	**286.59** ⭐
峰值输出 token 吞吐量 (tok/s)	15.00	345.00	**546.00** ⭐
峰值并发请求数	34.00	34.00	33.00
总 token 吞吐量 (tok/s)	1502.82	7751.49	**13183.13** ⭐

首Token延迟 (TTFT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TTFT (ms)	1813110.36	136676.31	**127502.93** ⭐
中位 TTFT (ms)	1826584.99	132208.13	**115177.94** ⭐
P95 TTFT (ms)	2098647.67	174965.55	**163893.99** ⭐
P99 TTFT (ms)	2179511.94	253761.11	**164229.17** ⭐

每Token生成时间 (TPOT)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 TPOT (ms)	270.88	962.85	**46.90** ⭐
中位 TPOT (ms)	275.03	991.56	**47.09** ⭐
P95 TPOT (ms)	441.40	1050.24	**47.34** ⭐
P99 TPOT (ms)	540.88	1054.50	**47.47** ⭐

Token间延迟 (ITL)

指标	Hygon_BW1000	Kunlun_P800	NVIDIA_H100
平均 ITL (ms)	265.46	959.55	**47.07** ⭐
中位 ITL (ms)	159.79	998.70	**26.17** ⭐
P95 ITL (ms)	**167.54** ⭐	1479.19	280.24
P99 ITL (ms)	2310.17	1524.63	**390.82** ⭐

📊 32并发性能比对柱状图

极限验证监控

- **海光**: 最大可处理请求12个，不过在1~12之间波动频繁，且缓存命中率较高（16%左右，正常应该在0~3%之间）
- **昆仑芯**: 最大可处理请求23个，同时处理请求数在18~23之间波动，基本稳定，缓存命中率波动较大，在2%~16%左右波动。
- **英伟达**: 最大可同时处理请求数14个，且非常稳定，缓存命中率波动正常，稳定维持在1%~3%之间。

测试场景四：多轮对话测试benchmark

测试目标

- **评估上下文一致性**：检验模型能否在连续多轮交互中准确记忆并引用历史对话内容，避免自相矛盾或信息丢失。
- **追踪用户意图演化**：识别用户目标在对话过程中的动态变化，并做出合理响应。
- **建模长程依赖关系**：验证模型对跨多轮、跨段落语义关联的理解能力和隐含前提的推理。
- **检验对话连贯性与自然性**：评估回复是否符合人类对话节奏，包括语气衔接、话题过渡与非指令性回应的合理性。
- **识别幻觉与错误累积**：检测模型在多轮中是否因错误信息传递而产生连锁性虚假陈述（如虚构事实、错误引用）。

测试概览

所有平台均采用了以下通用测试配置（除模型精度可能因硬件生态有所不同外）：

- 测试模型: MiniMax-M2.5
- 并发客户端 (num_clients): 10
- 总对话轮数 (num_conversations): 1000
- 活跃对话数 (active_conversations): 10
- 输入轮数 (input_num_turns): 10 (常量)
- 输入 Token 长度 (input_num_tokens): 200 (常量)
- 输出 Token 长度 (output_num_tokens): 100 (常量)
- 语料来源: vllm 推荐的语料 pg1184.txt (seed=0)

vLLM启动参数配置

同测试场景一

横向对比

为方便评估国产化替代方案，以下将 英伟达（NVIDIA） H100 作为行业基准（100%），对两款国产芯片（昆仑芯、海光）进行核心业务视角的横向对比。

核心业务指标横向对比表

芯片平台	算力产能 (吞吐量) (对比英伟达)	用户体感：首字响应 (对比英伟达)	用户体感：生成速度 (生成 1 个词耗时)
US 英伟达 (fp8)	100% (7.96 请求/秒)	极快 (~130 ms)	极丝滑 (11.35 ms, 约 88字/秒)
CN 昆仑芯 (INT8 量化)	35.5% (2.83 请求/秒)	良好，慢 2.5倍 (~327 ms)	流畅 (31.12 ms, 约 32字/秒)
CN 海光 (fp8)	7.7% (0.62 请求/秒)	迟缓，慢 5.7倍 (~744 ms)	卡顿 (150.87 ms, 约 6.6字/秒)

各平台详细统计数据 Logs

1. 英伟达 (NVIDIA)

- 总耗时: 627.925 秒 | RPS: 7.963

指标	count	mean	std	99%	99.9%	max
ttft_ms	5000	129.78	28.32	199.69	228.47	297.14
tpot_ms	5000	11.35	0.34	12.36	12.67	13.02
latency_ms	5000	1252.02	39.47	1337.41	1393.79	1410.12
input_num_turns	5000	5.00	2.83	9.00	9.00	9.00
input_num_tokens	5000	795.66	422.22	1395.00	1395.00	1395.00
output_num_tokens	5000	99.84	0.54	100.00	100.00	100.00
output_num_chunks	5000	98.88	0.61	99.00	99.00	99.00

2. 昆仑芯 (Kunlun)

- 模型版本: `MiniMax-M2.5-W8A8-INT8-Dynamic`
- 总耗时: 1763.187 秒 | RPS: 2.826

指标	count	mean	std	99%	99.9%	max
ttft_ms	5000	327.32	87.53	514.05	790.37	790.52
tpot_ms	5000	31.12	0.96	33.44	34.17	34.97
latency_ms	5000	3529.34	86.70	3730.24	3852.60	3852.80
input_num_turns	5000	4.99	2.83	9.00	9.00	9.00
input_num_tokens	5000	802.24	427.81	1418.00	1428.00	1433.00
output_num_tokens	5000	103.92	2.09	109.00	118.00	123.00
output_num_chunks	5000	97.42	1.38	99.00	99.00	99.00

3. 海光 (Hygon)

- 总耗时: 8128.131 秒 | RPS: 0.615

指标	count	mean	std	99%	99.9%	max
ttft_ms	5000	744.74	210.26	1087.50	1211.05	1385.32
tpot_ms	5000	150.87	3.73	159.02	161.85	163.93
latency_ms	5000	16228.04	171.00	16589.66	16737.82	16776.41
input_num_turns	5000	5.00	2.83	9.00	9.00	9.00
input_num_tokens	5000	803.30	427.66	1418.00	1428.00	1439.00
output_num_tokens	5000	103.67	2.23	111.00	119.00	122.00
output_num_chunks	5000	98.89	0.32	99.00	99.00	99.00

测试场景五：模型精度测试

测试目标

模型精度测试目标主要是通过标准指标（如准确率、精确率、召回率、F1值、mAP、AUC）衡量模型在测试集上的输出与真实标签的一致性，评估其基本判别能力。

vLLM启动参数配置

同测试场景一

测试说明

1. 由于本轮测试中海光的环境未完成精度测试，本报告只对比昆仑芯和英伟达的精度指标。

2. 不过本次测试的数据集是比较基础的文本数据集，minimax-m2 系列在 MMLU-Pro 这个数据集上拿到了 SOTA，得分 88 分。 又鉴于本次测试的模型量化精度不同，后续需要进行更低分值数据集的测试，进一步验证国产芯片在复杂数据集上的推理精度能力，尤其是量化后的模型，为后续选型提供更有力的参考依据。

MiniMax2.5 模型双平台芯片精度测试报告（数据集：MMLU-Pro）

汇报摘要（Executive Summary）： 在MMLU-Pro 综合能力测试中，英伟达芯片的整体模型精度（65.13%）略高于昆仑芯片（62.62%），两者相差 2.51%。 测试覆盖了14个学科领域，虽然英伟达在所有学科均保持微弱优势，但昆仑芯片的整体表现已具备极高的可用性，作为国产替代方案在绝大多数场景下差异不明显。

📈 详细数据看板（精度对比表）

*注：数据已转化为百分比（%），按差距从大到小排序，重点关注右侧的差异值。

测试学科 (Tasks)	英伟达精度	昆仑芯片精度	差异 (英伟达领先)	业务影响评估
整体平均 (Overall)	65.13%	62.62%	+ 2.51%	🟢 整体差异极小
哲学 (Philosophy)	59.32%	51.70%	+ 7.62%	🟡 差距显著
计算机科学 (CS)	71.46%	66.59%	+ 4.87%	🟡 差距较明显
其他综合 (Other)	69.48%	65.80%	+ 3.68%	🟢 可接受
化学 (Chemistry)	54.68%	51.06%	+ 3.62%	🟢 可接受
经济学 (Economics)	77.84%	74.88%	+ 2.96%	🟢 可接受
商业 (Business)	74.40%	71.61%	+ 2.79%	🟢 可接受
数学 (Math)	62.18%	59.66%	+ 2.52%	🟢 可接受
健康/医学 (Health)	67.48%	65.04%	+ 2.44%	🟢 可接受
物理 (Physics)	71.52%	69.52%	+ 2.00%	🟢 极微弱差异
历史 (History)	58.01%	56.17%	+ 1.84%	🟢 极微弱差异
生物 (Biology)	81.17%	79.50%	+ 1.67%	🟢 极微弱差异
心理学 (Psychology)	74.06%	72.43%	+ 1.63%	🟢 极微弱差异
工程学 (Engineering)	53.04%	52.32%	+ 0.72%	🟢 基本一致
法律 (Law)	46.59%	46.32%	+ 0.27%	🟢 基本一致

测试场景六：基础推理能力验证

测试目标：

验证模型在各芯片环境上的基础推理和兼容性的支持能力情况，可作为快速选型的一个基础指标。

态说明：✅ 已通过，⏳ 未测试，❌ 未通过，⚠️ 部分通过

A. 基础推理能力（8 项）

#	测试点	测试内容	英伟达	昆仑	海光	优先级
A1	单轮对话	发送单条 prompt，验证正常生成	✅	✅	✅	P0
A2	多轮对话	3-5 轮对话，验证上下文保持和连贯性	✅	✅	✅	P0
A3	System Prompt	设置系统角色，验证模型遵循程度	✅	✅	✅	P0
A4	流式输出	stream=true，验证 SSE 逐 token 返回	✅	✅	✅	P0
A5	非流式输出	stream=false，验证完整返回	✅	✅	✅	P0
A6	Max Tokens 限制	设置 max_tokens=50/100/500，验证输出不超限	✅	✅	✅	P0
A7	多语言能力	中/英/日/韩/法 等多语言输入输出	✅	✅	✅	P1
A8	特殊 Token 处理	含 emoji、代码块、数学符号、HTML 标签的输入	✅	✅	✅	P1

B. 高级生成功能（9 项）

#	测试点	测试内容	英伟达	昆仑	海光	优先级
B1	思考模式（Thinking）	开启 thinking mode，验证返回思考链 + 最终答案	✅	⚠️	⚠️	P0
B2	非思考模式（Instant）	关闭 thinking，拆分验证“请求可接受”与“无冗余推理”	✅	✅	✅	P0
B3	思考模式切换	同一会话内 thinking↔non-thinking 切换	✅	✅	✅	P1
B4	工具调用-单工具	定义单个 function，验证模型正确调用并传参	✅	✅	✅	P0
B5	工具调用-并行调用	单次回复中并行调用多个工具	✅	✅	✅	P1
B6	工具调用-多步链式	工具结果作为下一步输入，验证 3+ 步链式执行	✅	✅	✅	P1
B8	结构化输出	JSON Schema 约束输出格式，验证字段完整性	✅	✅	✅	P0
B9	单图理解	输入一张图片 + 文本提问，验证视觉理解	❌	❌	❌	P0

未通过测试点说明：Minimax-M2.5模型当前不支持图片理解

H. API 兼容性（4 项）

#	测试点	测试内容	英伟达	昆仑	海光	优先级	结果说明
H1	OpenAI Chat Completions	`/v1/chat/completions` 接口兼容，验证请求格式、返回格式完全兼容	✅	✅	✅	P0	
H2	OpenAI Completions	`/v1/completions` 接口兼容，验证传统 completion 格式支持	✅	✅	✅	P1	
H3	模型列表	`/v1/models` 返回可用模型，验证正确返回模型 ID 和元信息	✅	✅	✅	P1	`/v1/models` 当前返回 `object=list`，Minimax 2.5 模型能在列表中找到，且带 `id` / `created` / `owned_by` 等元信息
H4	Usage 统计	返回中 usage 字段准确，验证 `prompt_tokens + completion_tokens` 计数	✅	✅	✅	P0	

报告生成时间: 2026-03-26